

UNIVERSITÀ DEGLI STUDI DI SALERNO

DIPARTIMENTO DI INFORMATICA



Software Engineering for Artificial Intelligence

Progetto SE4AI Extended Abstract

Professore:

**Ch.mo Prof.
Fabio Palomba**

Tutor di riferimento:

Dott.ssa Alessandra Parziale

Studenti:

Antonio D'Auria

Mat. NF22500063

Daniele Pio Scaparra

Mat. NF22500101

Carla Stefanile

Mat. NF22500097

ANNO ACCADEMICO 2025/2026

Extended Abstract

ANTONIO D'AURIA, DANIELE PIO SCAPARRA, CARLA STEFANILE

Introduzione. I modelli di intelligenza artificiale generativa, in particolare i Large Language Models (LLMs), sono sempre più diffusi in numerosi contesti applicativi. Tuttavia, diversi studi hanno evidenziato come tali modelli possano esibire comportamenti non equi, producendo output influenzati da attributi sensibili dell'input, quali genere, etnia o religione [1, 3, 4].

La valutazione della fairness nei modelli linguistici è spesso basata su benchmark statici, che risultano limitati in termini di copertura e generalizzabilità. In questo contesto, il concetto di counterfactual fairness [2] rappresenta un principio utile: un modello è considerato equo se il suo output rimane invariato al variare di attributi sensibili non rilevanti.

In questo lavoro proponiamo un approccio ispirato a metodologie recenti di generazione automatica di test [5], volto alla costruzione e analisi di input controfattuali per lo studio e la mitigazione del bias nei modelli generativi.

Obiettivi del progetto. L'obiettivo del progetto è analizzare l'impatto delle feature sensibili sugli output dei modelli generativi di testo e studiare tecniche per la mitigazione dei bias osservati.

In particolare, il progetto si propone di:

- analizzare dataset e benchmark presenti in letteratura per identificare le feature sensibili più rilevanti in diversi contesti;
- costruire una rappresentazione strutturata di tali feature, organizzandole in categorie;
- generare input controfattuali a partire da prompt base, modificando in modo controllato le feature sensibili, seguendo un approccio ispirato a quello presentato da Sharma et al. [5];
- valutare come le variazioni delle feature influenzano il comportamento del modello;
- applicare e valutare strategie di mitigazione del bias.

In sintesi, il progetto mira a identificare le feature sensibili che influenzano il comportamento dei modelli generativi e a valutarne l'impatto attraverso test controfattuali, al fine di analizzare e mitigare il bias.

Metodologia. L'approccio proposto combina l'analisi di dataset esistenti con la generazione controllata di input, al fine di costruire una pipeline per la valutazione della fairness basata su test controfattuali.

La prima fase consiste nell'analisi di dataset e benchmark esistenti come CrowS-Pairs [4], StereoSet [3] e della letteratura di riferimento, con l'obiettivo di individuare le feature sensibili che maggiormente influenzano il comportamento dei modelli.

Le feature identificate vengono organizzate in categorie (ad esempio genere, etnia, religione), costruendo una tassonomia utilizzata nelle fasi successive.

Vengono selezionati specifici task applicativi e costruiti prompt di input progettati per essere neutri rispetto alle feature sensibili individuate, in modo da isolare l'effetto delle modifiche introdotte nelle fasi successive.

A partire dai prompt base, vengono generate varianti controfattuali modificando esclusivamente le feature sensibili identificate.

La generazione avviene attraverso trasformazioni rule-based (ad esempio sostituzioni dirette di attributi sensibili) ed eventualmente con il supporto di modelli linguistici, mantenendo il controllo sulle modifiche introdotte.

Questo processo consente di costruire coppie di input semanticamente equivalenti, differenziate unicamente rispetto alla feature sensibile considerata.

I modelli vengono eseguiti sia sugli input originali sia sulle rispettive varianti controfattuali.

Gli output vengono quindi confrontati per analizzare l'effetto delle modifiche introdotte.

La valutazione si basa sull'osservazione della stabilità degli output rispetto alle variazioni delle feature sensibili, distinguendo tra comportamenti invarianti e variazioni potenzialmente indicative di bias.

In particolare, ci ispiriamo al concetto di compliance introdotto in PromptPex [5], adattandolo al contesto della fairness. L'idea è quella di valutare in che misura il comportamento del modello rimanga coerente al variare di attributi sensibili non rilevanti per il task.

A tal fine, intendiamo definire una misura di "fairness compliance" che quantifichi la stabilità degli output tra input originali e controfattuali. Tale misura non rappresenta una metrica standard consolidata, ma una formulazione operativa ispirata alla nozione di compliance, utilizzata per analizzare sistematicamente il grado di dipendenza del modello dalle feature sensibili.

Sulla base dei risultati ottenuti, vengono applicate strategie di mitigazione, quali la riscrittura dei prompt o la riformulazione degli input. Successivamente, la pipeline di valutazione viene rieseguita per verificare eventuali miglioramenti nel comportamento del modello.

Conclusioni. Il progetto mira a sviluppare un approccio sistematico per l'analisi del bias nei modelli generativi, basato sulla costruzione di test controfattuali a partire da feature sensibili identificate in letteratura.

Attraverso questa pipeline, ci si aspetta di ottenere una migliore comprensione dell'impatto delle feature sensibili sugli output dei modelli e di individuare strategie efficaci per la mitigazione dei bias.

Concetti chiave. fairness, counterfactual fairness, bias mitigation, large language models, test generation.

Riferimenti bibliografici

- [1] Tolga Bolukbasi, Kai-Wei Chang, James Y Zou, Venkatesh Saligrama, and Adam T Kalai. 2016. Man is to computer programmer as woman is to homemaker? debiasing word embeddings. *Advances in neural information processing systems* 29 (2016).
- [2] Matt J Kusner, Joshua Loftus, Chris Russell, and Ricardo Silva. 2017. Counterfactual fairness. *Advances in neural information processing systems* 30 (2017).
- [3] Moin Nadeem, Anna Bethke, and Siva Reddy. 2021. StereoSet: Measuring stereotypical bias in pretrained language models. In *Proceedings of the 59th annual meeting of the association for computational linguistics and the 11th international joint conference on natural language processing (volume 1: long papers)*. 5356–5371.
- [4] Nikita Nangia, Clara Vania, Rasika Bhalerao, and Samuel Bowman. 2020. CrowS-pairs: A challenge dataset for measuring social biases in masked language models. In *Proceedings of the 2020 conference on empirical methods in natural language processing (EMNLP)*. 1953–1967.
- [5] Reshabh K Sharma, Jonathan De Halleux, Shraddha Barke, Dan Grossman, and Benjamin Zorn. 2025. Promptpex: Automatic test generation for language model prompts. *arXiv preprint arXiv:2503.05070* (2025).